



UNIVERSIDADE FEDERAL RURAL DO SEMIÁRIDO - UFERSA

PRÓ-REITORIA DE GRADUAÇÃO

DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA

**CURSO INTERDISCIPLINAR EM TECNOLOGIA DA
INFORMAÇÃO**

FRANCISCA LORRAYNE DE LIMA SANTOS
FRANCISCA SAMIRA AQUINO FRANÇA

TRABALHO COMPUTACIONAL 05 - REDES MLP

PAU DOS FERROS - RN
MAIO - 2026

RELATÓRIO – CLASSIFICAÇÃO DE INTRUSÕES EM REDES COM MLP UTILIZANDO PYTORCH

A segurança de redes de computadores representa um dos principais desafios da computação moderna, principalmente devido ao crescimento contínuo de ataques cibernéticos capazes de comprometer serviços, dados e infraestruturas críticas. Entre os ataques mais comuns destacam-se:

- DoS (*Denial of Service*);
- Probe;
- R2L (*Remote to Local*);
- U2R (*User to Root*).

Nesse contexto, os Sistemas de Detecção de Intrusão (IDS — *Intrusion Detection Systems*) desempenham papel fundamental na identificação automática de atividades maliciosas em redes de computadores.

Entretanto, devido à natureza não linear dos padrões presentes nos dados de tráfego de rede, modelos lineares simples, como o Perceptron, apresentam dificuldades para separar adequadamente conexões normais de conexões maliciosas. Dessa forma, redes neurais do tipo MLP (*Multilayer Perceptron*) tornam-se uma alternativa adequada, pois utilizam múltiplas camadas ocultas e funções de ativação não lineares, permitindo o aprendizado de relações complexas entre os atributos do conjunto de dados. Neste projeto foi utilizada uma rede MLP implementada em PyTorch para realizar a classificação binária de conexões da base NSL-KDD, considerando:

- 0 -> conexão normal;
- 1 -> ataque.

O dataset utilizado foi o NSL-KDD, uma versão refinada do KDD Cup 1999, amplamente utilizada em pesquisas relacionadas à detecção de intrusão.

O conjunto de dados possui:

- 41 atributos de entrada;
- 3 atributos categóricos:
 - protocol_type;

- service;
 - flag.
- 38 atributos numéricos;
- 1 atributo de saída contendo o tipo de ataque.

Os arquivos utilizados foram:

- KDDTrain+.txt;
- KDDTest+.txt.

O problema foi tratado como uma tarefa de classificação binária:

- normal -> 0;
- qualquer ataque -> 1.

A preparação dos dados foi realizada em etapas para garantir melhor desempenho e capacidade de generalização do modelo. Os arquivos foram carregados utilizando a biblioteca de pandas. A coluna difficulty_level foi removida, pois não participa diretamente do processo de classificação. Após isso foi feita a codificação One-Hot da seguinte forma:

- protocol_type;
- service;
- flag.

Que foram convertidos para valores numéricos utilizando a técnica de One-Hot Encoding. Em seguida foi realizada a binarização dos rótulos, onde foram convertidos para:

- 0 -> normal;
- 1 -> ataque.

Em subsequência, os atributos numéricos foram normalizados utilizando o método Z-score por meio do StandardScaler. A normalização foi ajustada apenas com os dados de treino, evitando vazamento de informação para o conjunto de testes. Além disso, a rede neural foi implementada utilizando a biblioteca PyTorch. A arquitetura escolhida foi composta por:

- Camada de entrada;
- Primeira camada oculta com 128 neurônios;

- Segunda camada oculta com 64 neurônios;
- Camada de saída com 1 neurônio.

As funções utilizadas foram:

- ReLU nas camadas ocultas;
- BCEWithLogitsLoss como função de perda;
- Adam como otimizador.

A camada de saída não utiliza função de ativação explícita, pois a função BCEWithLogitsLoss já aplica internamente a função sigmoide. O conjunto de treinamento foi dividido em:

- 80% para treino;
- 20% para validação.

O treinamento foi realizado durante 50 épocas, utilizando:

- Mini-batches de tamanho 256;
- DataLoader do PyTorch.

Durante o treinamento foram registradas:

- Loss de treino;
- Loss de validação.

Também foi aplicada a técnica de Early Stopping, utilizada para interromper o treinamento quando a validação deixasse de apresentar melhorias significativas, reduzindo o risco de overfitting. Após o treinamento, o modelo foi avaliado utilizando o conjunto KDDTest+.txt, que não participou do processo de treinamento. A saída da rede foi convertida em probabilidades utilizando a função sigmoide. Em seguida, foi aplicado um limiar de decisão de 0,5 para definir a classe prevista:

- Probabilidade menor que 0,5 -> conexão normal (0);
- Probabilidade maior ou igual a 0,5 -> ataque (1).

As métricas utilizadas foram:

- Acurácia;

- Precisão;
- Recall;
- F1-score;
- Matriz de confusão.

Após o treinamento da rede MLP, foram obtidos os seguintes resultados no conjunto de teste:


Métrica	Valor
Acurácia	0.7966
Precisão	0.9279
Recall	0.6969
F1-score	0.7960

Os resultados mostram que a rede neural obteve aproximadamente 79,66% de acurácia, demonstrando desempenho satisfatório para a tarefa de detecção de intrusão. A elevada precisão (92,79%) indica que, quando o modelo classifica uma conexão como ataque, essa previsão tende a estar correta na maioria das vezes, reduzindo a quantidade de falsos positivos. Por outro lado, o recall de 69,69% mostra que parte significativa dos ataques ainda não foi detectada, evidenciando a presença de falsos negativos relevantes. O F1-score de 79,60% demonstra um equilíbrio razoável entre precisão e recall.

Além disso, foi possível notar que o gráfico de treinamento demonstrou que a rede MLP apresentou convergência adequada durante o processo de aprendizado. Observou-se redução consistente tanto da loss de treino quanto da loss de validação nas primeiras épocas, indicando que o modelo conseguiu aprender padrões relevantes presentes no dataset. A curva de treino reduziu rapidamente de aproximadamente 0,09 para valores próximos de 0,01, enquanto a loss de validação estabilizou em torno de 0,015. Esses resultados indicam boa capacidade de generalização e ausência de sinais severos de overfitting.

Dessa forma, a utilização do Early Stopping foi importante para interromper o treinamento no momento em que a validação deixou de apresentar melhorias significativas, evitando que o modelo se ajustasse excessivamente aos dados de treino.

Figura 1 — Curvas de loss de treino e validação da MLP.



A matriz de confusão obtida foi:

[9016 695]

[3890 8943]

A partir disso foi possível interpretar que foram realizadas cerca de 9016 conexões normais foram classificadas corretamente; 695 conexões normais foram classificadas incorretamente como ataques (falsos positivos); 3890 ataques foram classificados incorretamente como conexões normais (falsos negativos); 8943 ataques foram identificados corretamente. Os falsos negativos representam o erro mais crítico em sistemas IDS, pois correspondem a ataques reais que não foram detectados pelo sistema. Apesar do bom desempenho geral, o número de falsos negativos ainda foi relativamente elevado, indicando que o modelo pode ser aprimorado futuramente para melhorar sua capacidade de detecção.

Em sistemas de detecção de intrusão, o erro mais crítico é o falso negativo. Um falso negativo ocorre quando um ataque é classificado como conexão normal. Nesse cenário, o

sistema deixa de identificar uma ameaça real, permitindo que o ataque continue acontecendo. Já o falso positivo ocorre quando uma conexão legítima é classificada como ataque. Embora cause inconvenientes e alarmes desnecessários, esse erro normalmente é menos grave do que permitir uma invasão real. Devido a isso, sistemas IDS geralmente priorizam um recall elevado, reduzindo a quantidade de falsos negativos. A escolha do limiar influencia diretamente esse comportamento:

Limiares menores

- aumentam o recall;
- reduzem falsos negativos;
- aumentam falsos positivos.

Limiares maiores

- aumentam a precisão;
- reduzem falsos positivos;
- aumentam falsos negativos.

Assim, em aplicações reais, muitas vezes utiliza-se um limiar inferior a 0,5 para aumentar a sensibilidade do sistema. Por fim, a rede MLP apresentou desempenho adequado para o problema de detecção de intrusão utilizando o dataset NSL-KDD. A utilização de múltiplas camadas ocultas e funções de ativação não lineares permitiu capturar padrões complexos presentes nos dados de tráfego de rede. Além disso, técnicas como:

- normalização;
- mini-batches;
- validação;
- early stopping;

Esses resultados demonstram que redes MLP constituem uma abordagem eficiente para tarefas de classificação binária em sistemas de segurança computacional.